

BUT1 – S.A.E. S2-04 STATISTIQUES

IUT DE NANTES – DÉPARTEMENT D'INFORMATIQUE

Contact : François Simonneau, Email : francois.simonneau@univ-nantes.fr

L'évaluation sera individualisée et elle s'effectuera essentiellement par le biais d'une évaluation sur python reprenant l'ensemble de ce sujet. Chaque question du sujet sera traitée par l'implémentation d'une fonction propre.

PARTIE 1 – INDEPENDANCE

1.1. **Cas théorique.** On imagine ici une entreprise ayant trois sites de production (appelés « Site 1 », « Site 2 » et « Site 3 ») et qui mène une étude sur les causes des arrêts sur ses chaînes de production. Quatre origines de défaillances ont été identifiées menant à ces arrêts et l'entreprise souhaite ici savoir s'il y a des tendances particulières qui apparaissent sur l'origine d'une défaillance selon le site de production. Autrement dit la problématique est de savoir si la défaillance a la même chance d'avoir telle ou telle origine quel que soit le site de production (indépendance des deux variables) et dans le cas contraire identifier les cas les plus singuliers (sur-représentation ou sous-représentation d'une origine dans un site par rapport à ce qui est observé sur l'ensemble des sites).

Pour mener cette étude des données ont été collectées sur l'échantillon des 250 derniers arrêts constatés sur l'ensemble des trois sites.

Effectifs observés	Electrique	Humaine	Mécanique	Réseau	Total
Site 1	10	10	14	22	56
Site 2	28	28	31	22	109
Site 3	25	9	30	21	85
Total	63	47	75	65	250

Pour mener cette étude une première idée naturelle peut être d'observer la répartition des origines des défaillances sur chacun des sites et de pouvoir comparer chacune à ce qui a été observé au niveau de l'ensemble de l'entreprise.

Répartitions observées	Electrique	Humaine	Mécanique	Réseau	Total
Site 1	17.9%	17.9%	25%	39.3%	100%
Site 2	25.7%	25.7%	28.4%	20.2%	100%
Site 3	29.4%	10.6%	35.3%	24.7%	100%
Total	25.2%	18.8%	30%	26%	100%

On souhaiterait établir un tableau avec les effectifs qu'on aurait théoriquement dû observer sur chaque croisement pour pouvoir affirmer « à 100% » que la fréquence de telle ou telle origine est

indépendante du site de production. Ce serait le cas si les fréquences observées dans le tableau étaient identiques sur chaque ligne et en particulier identique à celle observée sur l'ensemble de la « population » soit la ligne représentée par le total sur l'ensemble des trois sites de production (ceci va donc constituer une norme pour le calcul de ces effectifs théoriques).

Ainsi par exemple l'effectif $n_{(S1,E)}^t$ qu'on aurait théoriquement dû observer, sous hypothèse d'indépendance, sur le croisement entre les modalités « Site 1 » et « Electrique » doit respecter les égalités suivantes :

$$\frac{n_{(S1,E)}^t}{Tot_{(S1)}} = 25.2\% \Leftrightarrow \frac{n_{(S1,E)}^t}{Tot_{(S1,E)}} = \frac{Tot_E}{Tot_{echantillon}} \Leftrightarrow n_{(S1,E)}^t = \frac{Tot_{S1} \times Tot_E}{Tot_{echantillon}}$$

Ce raisonnement se généralise pour obtenir l'effectif théorique de chaque croisement en se basant sur les totaux observés pour chaque modalité en ligne et chaque modalité en colonne et l'effectif total de l'échantillon :

$$n_{(mod_{ligne}, mod_{colonne})}^t = \frac{Tot_{ligne} \times Tot_{colonne}}{Tot_{echantillon}}$$

Effectifs théoriques	Electrique	Humaine	Mécanique	Réseau
Site 1	14.1	10.5	16.8	14.6
Site 2	27.5	20.5	32.7	28.3
Site 3	21.4	16	25.5	22.1

Pour étudier la façon dont l'effectif observé sur chaque croisement s'est plus ou moins éloigné de l'effectif théorique attendu sous hypothèse d'indépendance, la première idée est de calculer des écarts entre ces deux effectifs pour chaque croisement. Néanmoins de manière générale la première attente est de prendre une décision sur le fait qu'on considère ou non que les deux variables sont globalement indépendantes ou non (même si dans le cadre de cet exercice on ne pourra pas apporter une réponse à cette question). On voudrait donc pouvoir cumuler tous ces écarts (en faire la somme) de sorte à rendre compte d'un écart global entre la situation observée et la situation théorique. Or si on effectue de simples écarts ceux-ci vont être tantôt négatifs, tantôt positifs et leur somme sera nulle. Pour éviter ceci on va élever tous ces écarts au carré. Enfin il convient de relativiser les écarts selon l'effectif théorique en divisant par celui-ci (on considère qu'un écart entre un effectif observé de 10 et un effectif théorique de 12 est davantage le témoin d'une dépendance qu'un même écart entre un effectif observé de 100 et un effectif théorique de 102). Le calcul final de ce qu'on appelle des contributions (chaque croisement contribue plus ou moins au fait de rejeter l'hypothèse d'indépendance) s'établit donc ainsi :

$$Contrib_{(mod_{ligne}, mod_{colonne})} = \frac{(n^{obs} - n^t)^2}{n^t}$$

Contributions	Electrique	Humaine	Mécanique	Réseau
Site 1	1.2	0.03	0.47	3.8
Site 2	0.01	2.75	0.09	1.42
Site 3	0.6	3.05	0.79	0.05

1.2. Implémentation.

Q. 1.1. Implémenter la fonction `calcul_eff_obs(mon_df,var_lignes,var_colonnes)` renvoyant un Dataframe avec les résultats attendus au format suivant (représentation du résultat pour `calcul_eff_obs(mon_df,var_lignes,var_colonnes)`) :

Style ...	Radio 1	Radio 2	Radio 3	Radio 4	Radio 5	Radio 6
Electro	12	11	39	42	18	19
Hip-Hop ...	4	6	46	18	31	58
Indie	4	9	14	8	15	7
Jazz	17	15	19	9	14	9
Musique ...	23	16	11	3	2	1
Pop	5	27	31	17	37	67
Rock	20	34	33	15	33	30
Variété	6	54	28	16	20	27

Q. 1.2. Implémenter la fonction `calcul_eff_theo(eff_obs)` renvoyant un Dataframe avec les résultats attendus au format suivant :

index	Radio 1	Radio 2	Radio 3	Radio 4	Radio 5	Radio 6
Electro	12.831	24.252	31.161	18.048	23.97	30.738
Hip-Hop ...	14.833	28.036	36.023	20.864	27.71	35.534
Indie	5.187	9.804	12.597	7.296	9.69	12.426
Jazz	7.553	14.276	18.343	10.624	14.11	18.094
Musique ...	5.096	9.632	12.376	7.168	9.52	12.208
Pop	16.744	31.648	40.664	23.552	31.28	40.112
Rock	15.015	28.38	36.465	21.12	28.05	35.97
Variété	13.741	25.972	33.371	19.328	25.67	32.918

Q. 1.3. Implémenter la fonction `calcul_contrib(eff_obs,eff_theo)` renvoyant un Dataframe avec les résultats attendus au format suivant :


index	Radio 1	Radio 2	Radio 3	Radio 4	Radio 5	Radio 6
Electro	0.053819...	7.241279...	1.972013...	31.78736...	1.486896...	4.482420...
Hip-Hop ...	7.911675...	17.32006...	2.763249...	0.393141...	0.390620...	14.20389...
Indie	0.271634...	0.065933...	0.156260...	0.067929...	2.909814...	2.3693446
Jazz	11.81594...	0.036717...	0.023532...	0.248246...	0.000857...	4.570622...
Musique ...	62.90290...	4.210073...	0.152987...	2.423580...	5.940168...	10.28991...
Pop	8.237072...	0.682630...	2.296697...	1.822720...	1.045984...	18.02364...
Rock	1.655026...	1.112910...	0.329253...	1.773409...	0.873529...	0.990850...
Variété	4.360896...	30.24675...	0.864452...	0.573033...	1.252391...	1.063938...

Q. 1.4. Implémenter une fonction `analyse_contrib(n,eff_obs,eff_theo,contrib)` renvoyant une liste de `n` tuples informant sur les plus grandes contributions au format suivant


`(mod_style,mod_radio,signe,valeur_contrib)` où `signe` sera représenté par le caractère '+' si l'effectif observé est supérieur à l'effectif théorique (tendance à une certaine attraction entre ces deux modalités) et par le caractère '-' si l'effectif observé est inférieur à l'effectif théorique (tendance à une certaine répulsion entre ces deux modalités).

Q. 1.5. Implémenter une fonction `diagrammes(eff_obs, eff_theo, ana_contrib, lien)` réalisant l’affichage dans une même figure des diagrammes permettant la comparaison entre des répartitions observées sur des sous-populations de l’échantillon (sur une première ligne) avec la répartition observée sur l’ensemble de l’échantillon (sur une deuxième ligne). Les sous-populations représentées sont celles apparaissant dans les principales contributions (données via l’argument `ana_contrib`) pour un lien de dépendance (« attractif » ou « répulsif ») selon l’argument passé avec `lien`. On donne ci-après quelques graphiques illustrant ce qui doit s’afficher lors de l’exécution de certains tests proposés dans le sujet. En complément voici quelques spécifications complémentaires aux consignes ci-dessus :


- Chaque croisement de sous-populations concerné par une contribution élevée sera représenté sur le diagramme circulaire par un secteur détaché du centre via l’utilisation du paramètre `explode`. Le détachement maximal sur l’ensemble des contributions analysées (attractives et répulsives confondues) pourra être fixé à 0.2. Le détachement sera inversement proportionnel au rang de la contribution représentée parmi l’ensemble de celles apparaissant dans `ana_contrib`.
- Une sous-population apparaissant sur plusieurs contributions sera représentée par un unique diagramme circulaire sur lequel les différents secteurs concernés par les contributions plus élevées seront mis en exergue.
- La légende est placée systématiquement sur la ligne où est représentée la répartition observée sur l’ensemble de l’échantillon. S’il y a moins de 4 graphiques à représenter sur la première ligne, on ne réservera pour cette légende qu’un seul emplacement correspondant sur la deuxième ligne. A partir de 4 emplacements ou plus sur la première ligne on réservera les deux derniers emplacements correspondants sur la deuxième ligne.



Comparaison entre répartition observée sur la sous population par rapport à celle de l'ensemble de la population sur liens répulsifs



Comparaison entre répartition observée sur la sous population par rapport à celle de l'ensemble de la population sur liens attractifs



Comparaison entre répartition observée sur la sous population par rapport à celle de l'ensemble de la population sur liens répulsifs

Aucun lien de dépendance de type répulsif à représenter